


National Tsing Hua University
11320IEEM 513600 Deep Learning and Industrial Applications
Homework 4
Name: 巫宛芸 Student ID: 113034601

1. (15 points) Experiment with different window sizes and steps. Train the model using 3 different combinations of window size and step. Evaluate the Mean Squared Error (MSE) for each configuration. Report the MSEs using a table and analyze the results.

Window Size	Step	MSE (Best Val Loss)
10	15	298.0547
15	10	46.3372
20	5	14.5117




比較了上表三種組合。第一組 (10, 15) 的 Val Loss 最高 ($MSE = 298.05$)，可能是因為輸入的資料太短樣本比較稀疏，加上每次 Step 間隔太大，導致模型學不到時間上的變化。第二組 (15, 10) 把輸入拉長、樣本變多，效果有變好 ($MSE = 46.34$)。第三組 (20, 5) 表現最好 ($MSE = 14.51$)，因為給模型的資訊更多、訓練次數也比較密集，因此模型更準確地抓到時間的規律。

2.

(i) (15 points) Include 'Volume' as an additional input feature in your model. Discuss the impact of incorporating 'Volume' on the model's performance.

(ii) (15 points) Explore and report on the best combination of input features that yields the best MSE. Briefly describe the reasons of your attempts and analyze the final, optimal input combination.



(i) 把 Volume 加進輸入資料後，模型的 Best Val Loss 反而從 14.51 變成 924，預測誤差變大。可能是因為 Volume 的變化太劇烈，跟價格沒有明確關係，反而讓模型更難學習。另外如果沒有標準化，數值太大也會影響訓練效果。因此可以發現，加越多特徵不一定越好，還要看資



料跟預測的相關性。

- (ii) 比較後發現最佳組合是 Open, High, Low, Close，這組 feature 提供完整價格資訊因此能協助模型學習價格變動預測。而 volume 可能因為關係較弱或是沒有標準化因此讓模型表現變更差。

Feature combinations	Best Val Loss (MSE)	Reasons
Close	6.3260	只用收盤價單一資訊作為 baseline。
Open, Close	15.2207	加入開盤價後稍微改善，但缺乏最高最低價變化。
High, Low, Close	4.3941	加入價格變動範圍後表現明顯提升
Open, High, Low, Close	1.6423	使用開盤/收盤價、最高/最低價等完整資訊後表現最佳。
Open, High, Low, Close, Volume	995.7443	加入 Volume 後 MSE 明顯上升，可能數量與價格關係較弱導致。

3. (15 points) Analyze the performance of the model with and without normalized inputs in Lab 4. You can use experimental results or external references (which must be cited) to support your conclusions on whether normalization improves the model's performance. (Approximately 100 words.)

With / without normalized	Best Val Loss (MSE)
normalized	7.5184
without normalized	14.5117



比較結果顯示，做過標準化的模型明顯優於未標準化時。推測因為原始價格變動大，容易導致模型訓練不穩定，而經過標準化後，每個特徵的數值都在相似的範圍，提升了學習效率和預測表現。Singh and Singh (2022)這篇文獻指出，未標準化的特徵可能讓模型誤判或過度依賴數值較大的變數，藉由標準化可以提升模型穩定性與預測準確度。

來源：Singh, D., & Singh, B. (2022). Feature wise normalization: An effective way of normalizing data. Pattern Recognition, 122, 108307. <https://www.sciencedirect.com/science/article/pii/S0031320321004878>

4. (10 points) Why should the window size be less than the step size in Lab 4? Do you think this is correct? If you use external sources, please include references to support your response. (Approximately 50 words.)

Lab 4 把 window size 設定得比 step size 小，可能是為了減少樣本重疊、降低計算負擔並且加快訓練速度。但我認為這樣會犧牲時間的連續性，因此模型可能會漏掉一些重要變化。在 Alghamdi et al.

(2022)這篇論文也提到應該根據行為特性調整 window 與 step 的大小，才能提升模型準確率。

來源：Alghamdi, S., Zhao, Z., Ha, D. S., Morota, G., & Ha, S. S. (2022). Improved pig behavior analysis by optimizing window sizes for individual behaviors. *Journal of Animal Science*, 100(11), 1–9.

<https://academic.oup.com/jas/article/100/11/skac293/6691203>

5. (15 points) Describe one method for data augmentation specifically applicable to time-series data. Cite references to support your findings. (Approximately 100 words.)

Time Warping 是一種常見用於時間序列資料的 data augmentation 方法。具體作法是把時間軸拉長或壓縮，讓模型學會不同速度下的變化。這樣可以幫助模型靈活處理各種資料，提升預測準確率。根據 Wen et al. (2022)這篇文獻的 survey，Time Warping 是最基本但效果也不錯的方法，常會跟 jittering 或 cropping 這些方法一起使用，讓訓練資料變得更多樣。

來源：Wen, Q., Sun, L., Yang, F., Song, X., Gao, J., Wang, X., & Xu, H. (2022). Time Series Data Augmentation for Deep Learning: A Survey. *arXiv preprint arXiv:2002.12478*.

<https://arxiv.org/abs/2002.12478>

6. Discuss how to handle window size during inference in different model architectures:

(i) (5 points) Convolution-based models

(ii) (5 points) Recurrent-based models

(iii) (5 points) Transformer-based models

Inference 階段時，這三種模型處理 window size 的方式有以下差異：

(i) Convolution-based models

例如 CNN 模型 inference 時會使用固定長度的 window size，每次只看當下那段輸入，不考慮歷史資料。

(ii) Recurrent-based models

譬如 RNN 和 LSTM 這些模型在預測時會記住前一狀態，因此 inference 時建議用和訓練時一樣的 window size，確保時間依賴關係穩定。另外，實務上也會用 sliding window 的方式，把資料一段一段丟進模型，持續做預測。

(iii) Transformer-based models

可以處理長序列，但考慮到記憶體和計算量，所以 inference 通常會限制最大輸入長度，設定合理的 window size，也會搭配 attention mask 控制模型只看重要的部分。

來源：Selvin, S., Vinayakumar, R., Gopalakrishnan, E. A., Menon, V. K., & Soman, K. P. (2017). Stock price prediction using LSTM, RNN and CNN-sliding window model. In 2017 International Conference on Advances in Computing, Communications, and Informatics (ICACCI) (pp. 1643–1647). IEEE.

<https://ieeexplore.ieee.org/abstract/document/8126078>